

Projet impacts environnementaux et sociétaux (IES)

Rapport technique

Sujet 2 : Diagnostics de Performance Energétique (DPE) proposé par Enedis

Membres du groupe :

- JOLY Pacôme
- SAKO Abdoulaye
- JOUANNET Raphaël
- MOMBO Bilim Bilim
- NYONKWE NYANGWA Russel Kamel
- DIACK Aida
- AMOUZOUVI Consolata Basilia Kanlé
- RAOUTO Danielle Nelly

Encadrants :

- SMIRNOV Viktor
- GIRAULT Jean-Marc

Année académique 2025 - 2026

Sommaire

Sommaire.....	2
1. Contexte du projet.....	3
2. Présentation du Diagnostic de Performance Énergétique (DPE).....	3
3. Enjeux environnementaux, économiques et sociétaux.....	3
4. Cadre du projet.....	4
5. Problématique.....	4
6. Organisation du projet.....	4
7. Outils utilisés.....	5
8. Données utilisées.....	5
9. Diagramme : Logique du projet.....	6
I. Analyse des données.....	7
1. Description de la base de données (dataset).....	7
2. Nettoyage structurel du jeu de données.....	8
3. Définition de la variable cible.....	8
4. Gestion des valeurs manquantes.....	9
5. Choix des caractéristiques (features).....	10
6. Constitution du jeu de données final.....	11
II. Création des modèles.....	12
1. Modèle de prédiction du DPE.....	12
2. Modèle de prédiction de consommation énergétique.....	14
III. Visualisation des données.....	17
1. Premières visualisations avec Excel et Jupyter (phase exploratoire)...	17
2. Transition vers une interface interactive : choix de Streamlit.....	18
3. Développement du simulateur énergétique avec streamlit.....	18
Conclusion.....	22
Perceptives.....	23
Références.....	24

I. Contexte du projet

La transition énergétique est aujourd'hui au cœur des préoccupations environnementales et sociétales. Le secteur du bâtiment représente une part importante de la consommation énergétique (24% [1]) et des émissions de gaz à effet de serre (13% [2]), notamment à travers le chauffage, l'isolation et les équipements utilisés dans les logements. Dans ce contexte, l'amélioration de la performance énergétique des habitations constitue un levier essentiel pour réduire l'impact environnemental et maîtriser les dépenses énergétiques des ménages.

Ce projet s'inscrit dans cette dynamique et est proposé dans le cadre d'un programme porté par **Open Data University**, dont l'objectif est de sensibiliser les étudiants à l'utilisation des données ouvertes et aux enjeux actuels à travers des projets concrets.

II. Présentation du Diagnostic de Performance Énergétique (DPE)

Le Diagnostic de Performance Énergétique (DPE) est un indicateur réglementaire permettant d'évaluer la consommation énergétique d'un logement ainsi que son impact en termes d'émissions de gaz à effet de serre. Il attribue au logement une classe énergétique, généralement comprise entre A et G, où la classe A correspond aux logements les plus performants et la classe G aux plus énergivores.

Le DPE joue un rôle central dans l'information des propriétaires et des locataires, notamment lors de la vente ou de la location d'un bien immobilier. Il constitue également un outil d'aide à la décision pour engager des travaux de rénovation énergétique.

III. Enjeux environnementaux, économiques et sociétaux

Les enjeux liés au DPE sont multiples. Sur le plan environnemental, l'amélioration de la performance énergétique des logements contribue à la réduction des émissions de CO₂ et à la lutte contre le changement climatique. D'un point de vue économique, une meilleure efficacité énergétique permet de diminuer les factures d'énergie et d'optimiser les investissements liés aux travaux de rénovation. Enfin, sur le plan sociétal, ces améliorations participent à la lutte contre la précarité énergétique et favorisent un meilleur confort de vie pour les occupants.

Ainsi, disposer d'outils permettant d'analyser, de comprendre et d'anticiper la performance énergétique des logements représente un enjeu majeur pour les particuliers comme pour les acteurs publics.

IV. Cadre du projet

Ce projet est réalisé dans un cadre académique et s'inscrit dans une démarche de data science. Il est mené avec l'accompagnement de **l'association Latitude**. Des temps d'échange sont organisés avec des référents, que les étudiants peuvent contacter afin de poser des questions, obtenir des conseils méthodologiques et valider certaines orientations du projet.

L'objectif de ce travail est à la fois pédagogique et appliqué : il vise à mobiliser des techniques d'analyse de données, de visualisation et de modélisation afin d'exploiter un jeu de données portant sur les caractéristiques des logements et leur Diagnostic de Performance Énergétique, tout en mettant en pratique les compétences acquises tout au long de notre parcours.

V. Problématique

Dans le cadre de ce projet, la problématique retenue est la suivante :

Comment prédire la consommation énergétique des logements selon qu'ils aient ou non fait l'objet de travaux de rénovation, et comment estimer le nouveau Diagnostic de Performance Énergétique (DPE) après ces travaux ?

VI. Organisation du projet

Le projet est réalisé en groupe de huit personnes, réparties en quatre sous-groupes de deux afin de structurer le travail et d'assurer une bonne répartition des tâches. Chaque sous-groupe est responsable d'un axe spécifique du projet :

- **Gestion de projet** : organisation générale, suivi de l'avancement et coordination entre les sous-groupes
- **Analyse de données** : exploration du jeu de données et compréhension des variables
- **Data science** : mise en place et entraînement des modèles

- **Visualisation des données** : création de visualisations pertinentes pour l'analyse et la restitution des résultats

Cette organisation permet de travailler de manière efficace tout en favorisant les échanges entre les différents axes du projet.

VII. Outils utilisés

Pour mener à bien ce projet, plusieurs outils ont été mobilisés :

- **Python et Jupyter Notebooks** : pour l'exploration des données, l'analyse et la modélisation
- **Lucidchart** : pour la création de diagrammes et la représentation de la logique du projet
- **Teams** : pour la communication, le partage de documents et le suivi des tâches au sein du groupe
- **Github** : pour le versionnage des codes et la gestion collaborative du projet

Ces outils permettent de combiner travail collaboratif, analyse technique et visualisation structurée du projet.

VIII. Données utilisées

La base de données utilisée pour ce projet provient des DPE (Diagnostics de Performance Énergétique) des logements existants depuis juillet 2021, mise à disposition par l'ADEME et mise à jour le 13 décembre 2025.

Cette base contient des informations sur environ 8 000 de logements. Il est important de noter que le DPE n'est pas obligatoire pour tous les logements : il ne l'est que dans certains cas, notamment lors de la vente ou de la mise en location, ainsi que pour les logements neufs.

La base contient des métadonnées détaillant les caractéristiques des logements et les informations nécessaires au calcul du DPE. Ces données permettront de réaliser à la fois des analyses exploratoires, la modélisation de la consommation énergétique et l'estimation du DPE des logements avant et après travaux.

IX. Diagramme : Logique du projet

Le logigramme ci-dessous (Figure 1) présente de manière synthétique la logique globale du projet, en mettant en évidence les entrées, les modèles développés, les estimateurs et les sorties attendues :

- Entrées (Inputs) : caractéristiques des logements (surface, type de logement, équipements, etc.), DPE actuel
- Modèles développés :
 - Modèle de régression pour prédire la consommation énergétique
 - Modèle de classification pour estimer le DPE
- Estimateurs : erreur de régression et de DPE
- Sorties (Outputs) :
 - Consommation énergétique estimée après travaux
 - Classe énergétique (DPE) estimée après travaux




Figure 1 : Diagramme logique

X. Analyse des données

L'objectif de cette étape est de préparer un jeu de données issu des Diagnostics de Performance Énergétique (DPE) afin de le rendre exploitable pour une tâche de prédiction de la consommation énergétique des logements.

1. Description de la base de données (dataset)

Les données sont fournies sous la forme d'un fichier Excel contenant les caractéristiques énergétiques et structurelles des logements évalués constitué de 10000 lignes et de 225 colonnes. Chaque ligne correspond à un logement et chaque colonne à une variable descriptive. Les données sont chargées et manipulées à l'aide de la bibliothèque pandas, adaptée au traitement de grands volumes de données tabulaires.

Les données brutes présentent une forte hétérogénéité, un grand nombre de variables administratives et techniques, ainsi que des valeurs manquantes et redondantes susceptibles de dégrader les performances des modèles de machine Learning.

Le prétraitement vise ainsi à :

- Améliorer la qualité statistique des données,
- Réduire la dimensionnalité du jeu de données,
- Éliminer les variables non informatives ou redondantes,
- Prévenir toute fuite d'information lors de la phase de modélisation.

2. Nettoyage structurel du jeu de données

Une analyse descriptive préliminaire est réalisée afin de :

- Quantifier la proportion de valeurs manquantes par variable,
- Identifier la nature des variables (numériques ou catégorielles).

Cette étape permet d'orienter les choix de suppression ou de conservation des variables et de préparer les stratégies d'imputation ultérieures.

2.1. Suppression des variables

Les variables dont l'intégralité des valeurs est manquante sont supprimées. Ces colonnes ne contiennent aucune information exploitable et ne peuvent contribuer à la modélisation. Cette étape permet de réduire la dimension du jeu de données sans perte d'information pertinente.

2.2. Suppression des variables constantes

Les variables présentant une variance nulle (une seule valeur unique sur l'ensemble des observations) sont éliminées. De telles variables ne possèdent aucun pouvoir discriminant et ne peuvent améliorer la capacité prédictive des modèles.

2.3. Elimination des doublons

Les observations strictement identiques sont supprimées afin d'éviter toute sur-représentation artificielle de certains logements et de garantir l'indépendance statistique des échantillons.

3. Définition de la variable cible

La variable cible correspond à une mesure quantitative de la consommation énergétique du logement. Les variables issues directement du calcul DPE, telles que les étiquettes de consommation énergétique ou d'émission de gaz à effet de serre (classes A à G), ne sont pas utilisées comme variables explicatives afin d'éviter toute fuite d'information.

Une transformation logarithmique de la consommation énergétique est appliquée afin de réduire l'asymétrie de la distribution et de limiter l'influence des valeurs extrêmes. Cette transformation est couramment utilisée pour les variables énergétiques, dont la distribution est généralement fortement asymétrique.

Nous avons fait une représentation de la distribution des valeurs de la variable cible (Figure 2) :




Figure 2 : Boxplot de la distribution de la consommation finale

La distribution des consommations électriques est fortement asymétrique à droite, avec une majorité de logements présentant des consommations modérées et une grande quantité de valeurs élevées. Cette hétérogénéité reflète à la fois des différences structurelles entre bâtiments (taille, isolation, mode de chauffage) et des effets d'agrégation liés aux consommations par adresse.

4. Gestion des valeurs manquantes

Les variables présentant un taux de valeurs manquantes supérieur à un seuil prédéfini (par exemple 80 %) sont supprimées. La conservation de ces variables impliquerait une imputation excessive, susceptible d'introduire un bruit important et de dégrader les performances du modèle. Les variables restantes conservent une quantité suffisante d'informations observées pour être exploitables lors de la modélisation.

5. Choix des caractéristiques (features)

Le choix des caractéristiques utilisées pour l'entraînement des modèles a fait l'objet d'une réflexion particulière. Les variables retenues sont celles qui nous semblaient à la fois pertinentes pour la prédiction et facilement compréhensibles par un utilisateur final. Ce choix s'inscrit dans l'objectif de proposer un outil accessible, notamment dans la perspective du développement d'une interface utilisateur.

Les caractéristiques sélectionnées permettent de décrire à la fois les propriétés physiques du logement, ses équipements énergétiques et ses indicateurs de performance énergétique. Elles sont les suivantes :

- **type_batiment** : type de bâtiment (maison individuelle, appartement, etc.)
- **type_installation_chauffage** : type de système de chauffage installé
- **type_installation_ecs** : type de production d'eau chaude sanitaire
- **hauteur_sous_plafond** : hauteur moyenne sous plafond du logement
- **surface_habitable_logement** : surface habitable totale du logement
- **nombre_niveau_logement** : nombre de niveaux du logement
- **code_postal** : localisation géographique du logement, permettant de prendre en compte les différences climatiques régionales
- **Isolation** : niveau ou présence d'isolation du logement
- **type_energie_principale** : source d'énergie principale utilisée

Certaines variables directement liées à la performance énergétique ont également été retenues afin d'améliorer la qualité des prédictions :

- **etiquette_dpe** : classe énergétique du logement

- **etiquette_ges** : classe d'émission de gaz à effet de serre
- **conso_finale** et **conso_primaire** : consommations énergétiques mesurées ou estimées
- **cout_conso** : coût estimé de la consommation énergétique

L'ensemble de ces caractéristiques constitue un compromis entre richesse informative et simplicité d'interprétation. Elles permettent d'entraîner des modèles capables de prédire la consommation énergétique et le DPE, tout en restant cohérentes avec les informations qu'un utilisateur peut raisonnablement fournir lors de la simulation de scénarios de rénovation.

- Exploration du dataset : distribution des variables, statistiques descriptives
- Identification des valeurs manquantes et des anomalies
- Sélection des variables pertinentes pour les modèles
- Visualisations préliminaires pour comprendre les relations (histogrammes, corrélations...)

6. Constitution du jeu de données final

À l'issue du prétraitement, le jeu de données final est caractérisé par :

- Une structure épurée et cohérente,
- Des variables explicatives pertinentes,
- Une variable cible fiable et statistiquement exploitable,
- Une réduction significative de la dimensionnalité initiale.

Ce jeu de données est ainsi adapté à une intégration dans un pipeline de machine Learning comprenant encodage des variables catégorielles, imputation des valeurs manquantes résiduelles et entraînement de modèles de régression.

Le jeu de données final est exporté dans des formats standards (Excel et CSV).

Le prétraitement réalisé permet ainsi de transformer un jeu de données DPE brut, complexe et hétérogène en un jeu de données structuré, cohérent et exploitable pour la prédiction de la consommation énergétique et constitué de 14 colonnes et 8700 lignes. Les choix méthodologiques effectués reposent sur des considérations statistiques, physiques et méthodologiques visant à garantir la robustesse et la validité des modèles développés par la suite.

XI. Création des modèles

Dans cette partie, l'objectif est de définir les modèles d'intelligence artificielle qui seront utilisés tout au long du projet et dont les entrées correspondent aux caractéristiques décrites précédemment. Notre projet repose sur deux modèles dont le premier vise à prédire le Diagnostic de Performance Énergétique (DPE) du logement, tandis que le second permet d'estimer sa consommation énergétique.

1. Modèle de prédiction du DPE

Le premier modèle concerne la prédiction du Diagnostic de Performance Énergétique (DPE) en fonction des paramètres saisis par l'utilisateur.

En amont du modèle, des étapes de prétraitement sont ajoutées à l'aide d'un *StandardScaler* et d'un *OneHotEncoder*. Le *StandardScaler* permet de normaliser les données afin d'obtenir des variables de même échelle, tandis que le *OneHotEncoder* convertit les variables catégorielles en un encodage *one-hot*, c'est-à-dire sous forme de colonnes binaires, facilement exploitables par le modèle.

Pour réaliser la prédiction du DPE, une approche de classification par apprentissage automatique a été retenue, basée sur un modèle XGBoost (*Extreme Gradient Boosting*), reconnu pour sa robustesse. Ce modèle a été choisi pour sa capacité à modéliser efficacement des interactions complexes sur des données tabulaires mixtes, tout en utilisant des hyperparamètres modérés afin de limiter le surapprentissage. La classification est particulièrement adaptée à la prédiction du DPE, les différentes étiquettes pouvant être assimilées à des classes distinctes. L'ensemble de la pipeline a été implémenté à l'aide de la bibliothèque *scikit-learn*, garantissant ainsi la reproductibilité et la facilité de déploiement du modèle.

Après le prétraitement des données, la classification est effectuée avec un nombre d'estimateurs (*n_estimators*) fixé à 600 et une profondeur maximale (*max_depth*) de 6. Ces hyperparamètres ont été déterminés par une méthode de recherche dichotomique, consistant à tester successivement différentes valeurs afin d'identifier celles offrant les meilleures performances.

Afin de valider le choix du modèle, plusieurs métriques d'évaluation sont analysées : la précision (*precision*), le rappel (*recall*) et le score F1 (*F1-score*) pour chaque

classe. La précision mesure la proportion de prédictions positives correctement réalisées, tandis que le rappel indique la capacité du modèle à identifier l'ensemble des instances positives. Enfin, le score F1 fournit une mesure synthétique de la performance du modèle en combinant précision et rappel.

Pour compléter ces métriques, une matrice de confusion (figure 3) est également présentée afin de mieux visualiser et comprendre la répartition des erreurs de prédiction sur le jeu de validation.




Figure 3 : matrice de confusion sur la prédiction du DPE

La matrice de confusion (figure 3) est normalisée et exprimée en pourcentage afin de faciliter la lecture pour chaque classe. Elle représente la proportion de classes prédites par rapport aux classes réelles. Cette visualisation met en évidence une excellente diagonalisation pour les classes centrales C, D et E, avec seulement quelques confusions entre classes voisines. En revanche, des confusions plus marquées sont observées pour les classes A et B. Ce phénomène s'explique par le faible nombre de logements appartenant à ces classes dans le jeu de données, ce qui limite la capacité du modèle à apprendre correctement leurs caractéristiques et à bien généraliser.

Malgré cela, les performances globales du modèle demeurent élevées, avec un score F1 macro moyen de 0,85 (valeur que l'on cherche à rapprocher de 1) et un

écart-type de 0,019. Ces résultats traduisent une bonne robustesse et une stabilité du modèle.

L'utilisation du modèle de classification est illustrée dans le diagramme présenté en figure 1.

2. Modèle de prédiction de consommation énergétique

La seconde prédiction concerne la consommation énergétique du logement (en kW/an), également estimée à partir des données saisies par l'utilisateur.

Avant l'entraînement du modèle, un prétraitement des données est appliqué afin de standardiser les entrées et d'améliorer la qualité des prédictions. Un nettoyage initial est réalisé pour supprimer les valeurs manquantes de la variable cible « conso_finale », le modèle ne pouvant pas apprendre à partir d'observations dépourvues de valeur à prédire. Par ailleurs, des valeurs manquantes sont également présentes dans d'autres variables du jeu de données : celles-ci sont imputées par la médiane pour les variables numériques et par la modalité la plus fréquente pour les variables catégorielles. Enfin, les variables catégorielles sont transformées en vecteurs numériques à l'aide d'un *OneHotEncoder*, conformément à la méthodologie utilisée pour la prédiction du DPE.

Pour cette tâche de régression, le modèle retenu est le *HistGradientBoostingRegressor* (régression par ensemble avec amplification de gradient). Cet algorithme, basé sur des arbres de décision comme pour la prédiction du DPE, est particulièrement adapté au traitement de données tabulaires. Il exploite également une technique de *binning* (histogrammes), permettant d'accélérer l'entraînement sur des volumes de données importants, ce qui est le cas ici avec environ 6 000 observations dans le jeu d'entraînement. Enfin, l'utilisation d'une fonction de perte de type *Poisson* garantit des prédictions strictement positives de la consommation énergétique, en adéquation avec la réalité physique du problème.

Afin de vérifier la capacité du modèle à généraliser la prédiction de la consommation énergétique en fonction des différents paramètres d'entrée, plusieurs métriques d'évaluation sont analysées, notamment le coefficient de

détermination R^2 et la racine de l'erreur quadratique moyenne (RMSE). La comparaison entre la consommation prédite et la consommation réelle est également présentée à l'aide d'une courbe illustrée en figure 4.



Figure 4 : Courbe de validation entre les valeurs réelles et prédites

MAE : 683.71

RMSE : 1730.63

R^2 : 0.98

Les résultats obtenus montrent que le modèle de prédiction de la consommation énergétique fonctionne très bien. La MAE est de 683,71 kW/an, ce qui signifie qu'en moyenne, l'erreur entre la valeur réelle et la valeur prédite reste relativement faible par rapport aux niveaux de consommation annuelle d'un logement.

La RMSE est de 1 730,63 kW/an. Cette valeur, plus sensible aux grosses erreurs, indique que le modèle peut parfois se tromper davantage sur certains logements, mais ces cas restent limités. L'écart entre la MAE et la RMSE montre qu'il existe quelques erreurs plus importantes, sans pour autant remettre en cause la qualité globale du modèle.

Enfin, le coefficient R^2 est de 0,98, ce qui signifie que le modèle explique presque toute la variabilité de la consommation énergétique. Ce score très élevé montre que les variables utilisées sont pertinentes et que le modèle généralise bien sur les données.

Dans l'ensemble, ces résultats sont très satisfaisants et confirment que le modèle est fiable pour estimer la consommation énergétique à partir des informations fournies par l'utilisateur.

XII. Visualisation des données

1. Premières visualisations avec Excel et Jupyter (phase exploratoire)

Utilisation d'Excel

La première étape du projet a consisté à exploiter une petite base de données dans Excel afin de réaliser des visualisations simples :

- Graphiques de consommation énergétique,
- Premières comparaisons entre logements,
- Compréhension des ordres de grandeur des consommations (kWh, kWh/m²).

Excel a permis une prise en main rapide des données et une première analyse descriptive.

Cependant, cette approche s'est révélée limitée pour plusieurs raisons :

- Manque d'interactivité
- Difficulté à automatiser les calculs
- Impossibilité de simuler facilement plusieurs scénarios




Figure 4 : Visualisation des données sur une petite base de données dans Excel

Utilisation de Jupyter Notebook

Dans un second temps, les visualisations ont été réalisées sous Jupyter Notebook, à l'aide de bibliothèques Python telles que :

- Pandas pour la manipulation des données,
- Matplotlib pour les graphiques.

Cette étape a permis :

- Une meilleure structuration du code,
- La reproductibilité des calculs,
- La création de graphiques plus précis que sous Excel.

Néanmoins, Jupyter reste un outil orienté analyse technique, peu adapté à un utilisateur final non technique.

2. Transition vers une interface interactive : choix de Streamlit

Face aux limites d'Excel et de Jupyter, nous avons décidé de développer une interface interactive dédiée, capable de :

- Recueillir des entrées utilisateur,
- Effectuer des calculs dynamiques,
- Afficher des visualisations claires et pédagogiques.

La bibliothèque Streamlit a été choisie pour sa simplicité de mise en œuvre, son intégration directe avec Python et sa génération rapide d'interfaces web interactives.

3. Développement du simulateur énergétique avec streamlit

Modélisation et visualisation graphique des classes DPE

Dans un premier temps, une modélisation des classes DPE (A à G) a été implémentée.

Chaque classe est définie par :

- Un intervalle de consommation énergétique (kWh/m²/an),
- Une couleur normalisée conforme à l'étiquette officielle.

Cette modélisation permet de transformer une consommation calculée en classe énergétique lisible et interprétable.

Une visualisation graphique du DPE a ensuite été développée, reproduisant fidèlement l'étiquette officielle :

- Barres colorées de A à G,
- Mise en évidence de la classe calculée,
- Affichage de la consommation énergétique normalisée (kWh/m²/an),
- Indicateur visuel permettant d'identifier rapidement la position du logement.

Cette visualisation constitue un élément central de l'application.




Figure 5 : Visualisation graphique des classes DPE

Interface utilisateur :

L'interface Streamlit permet à l'utilisateur de renseigner de nombreuses caractéristiques du logement, notamment :

- Surface habitable,
- Type de bâtiment (maison / appartement),
- Code postal et localisation,
- Type de chauffage (individuel / collectif),
- Énergie de chauffage,
- Qualité de l'isolation,
- Type de fenêtres,
- Hauteur sous plafond et nombre de niveaux,
- Étiquettes DPE et GES (si connues).

☐ Mode Debug

Localisation
Code postal
75000
Ville
Veuillez saisir la ville

Type de logement
Type de bâtiment
Veuillez sélectionner

Prédiction de Consommation Énergétique
Prédisez votre consommation et simulez l'impact de travaux de rénovation

Informations du logement
Scénarios de rénovation
streamlitApp

Caractéristiques du logement

Surface habitable (m²)

100

- +

Année de construction

1990

- +

Nombre de niveaux

2

- +

Hauteur sous plafond (m)

2.50

- +

Type installation chauffage

Veuillez sélectionner

Énergie et isolation

Énergie principale chauffage

Veuillez sélectionner

Isolation des murs

Veuillez sélectionner

Type installation eau chaude sanitaire (ECS)

Veuillez sélectionner

Isolation du sous-sol

Veuillez sélectionner

Figure 6 : Interface qui permet à l'utilisateur d'entrer les caractéristiques de son logement

Un bouton de validation explicite est utilisé pour lancer le calcul, afin d'éviter l'affichage automatique de résultats par défaut et de renforcer la logique utilisateur.



Figure 7 : Bouton de validation pour lancer la prédiction

Visualisation de la consommation énergétique :

Le simulateur affiche plusieurs indicateurs clés :

- Consommation énergétique annuelle (kWh/an)
- Consommation surfacique (kWh/m²/an)
- Coût énergétique annuel estimé (€)
- Classe énergétique correspondante

Le tarif standard du kWh est affiché et utilisé pour le calcul du coût annuel, ce qui permet une lecture économique en complément de l'analyse énergétique.

Résultats de la prédiction

Consommation annuelle	Consommation/m ²	Coût annuel estimé	Classe DPE
2,737 kWh/an	27.4 kWh/m ² ...	493 €/an	A




Figure 8 : Résultats renvoyés par les modèles

Scénario de rénovation

Une seconde partie de l'application est dédiée aux scénarios de rénovation, permettant de simuler l'impact de travaux tels que :

- Agrandissement du logement
- Amélioration de l'isolation
- Changement du système de chauffage
- Modernisation de l'eau chaude sanitaire

Informations du logement Scénarios de rénovation

Choisissez un ou plusieurs scénarios de rénovation

Modifiez les caractéristiques du logement selon vos travaux envisagés

- > Scénario 2 : Modernisation de l'eau chaude sanitaire
- > Scénario 3 : Amélioration de l'isolation de l'enveloppe
- > Scénario 4 : Amélioration du système de chauffage

SIMULER LE(S) SCÉNARIO(S)

Figure 9 : Interface qui permet à l'utilisateur de simuler un scénario de rénovation

L'utilisateur peut activer un ou plusieurs scénarios, modifier uniquement les caractéristiques souhaitées, et comparer avant/après, afin de visualiser le gain.

Simulation terminée ! 1 scénario(s) appliqué(s)

Comparaison AVANT / APRÈS rénovation

Consommation annuelle	Consommation/m ²	Coût annuel	Classe DPE	Réduction
6,713 k...	67.1 kW...	1,208 €/an	A	0.0%
↑ +0 kWh	↑ +0.0	↑ +0 €	↑ A → A	↑ 0 kWh



Figure 10 : Résultats obtenus après une rénovation

Mais cette fonctionnalité n'a pas pu être implémentée à ce stade en raison de contraintes de temps. En conséquence, les scénarios de rénovation décrits ci-dessus (figure 10) ne sont pas encore pris en compte dans les calculs, ce qui explique pourquoi l'illustration présentée ne montre actuellement aucune variation des résultats (consommation énergétique et classe DPE) entre l'état initial et l'état après travaux.

Conclusion

Ce projet avait pour objectif de développer un outil permettant d'analyser et de prédire la performance énergétique des logements à partir de données issues des Diagnostics de Performance Énergétique (DPE). Dans un contexte de transition énergétique et de hausse des coûts de l'énergie, disposer d'un tel outil représente un réel intérêt, aussi bien pour les particuliers que pour les acteurs du secteur du bâtiment.

À partir d'une base de données ouverte fournie par l'ADEME, un important travail de prétraitement a été réalisé afin de transformer un jeu de données brut, hétérogène et incomplet en un dataset exploitable pour des tâches de

modélisation. Ce travail a permis de sélectionner des variables pertinentes, de gérer les valeurs manquantes et de réduire la dimensionnalité tout en conservant une information suffisante pour l'apprentissage des modèles.

Deux modèles de machine learning ont ensuite été développés : un modèle de régression pour prédire la consommation énergétique des logements et un modèle de classification pour estimer leur classe DPE. Les résultats obtenus montrent de bonnes performances, avec une forte capacité de généralisation, notamment pour la prédiction de la consommation énergétique, et une classification du DPE globalement cohérente, en particulier pour les classes intermédiaires.

Enfin, le développement d'une interface interactive avec Streamlit permet de rendre ces résultats accessibles à un utilisateur non technique. Le simulateur offre la possibilité de visualiser la consommation énergétique, le DPE associé et d'évaluer l'impact de différents scénarios de rénovation, ce qui constitue un véritable outil d'aide à la décision. Ce projet a ainsi permis de mettre en pratique des compétences en data science, en analyse de données et en visualisation, tout en répondant à une problématique concrète et actuelle.

Perceptives

Plusieurs pistes d'amélioration et d'évolution peuvent être envisagées pour prolonger ce travail. Tout d'abord, l'enrichissement du jeu de données, notamment par l'ajout de logements mieux représentés dans les classes A et B, permettrait d'améliorer la qualité de l'apprentissage et de réduire les confusions observées dans la classification du DPE.

Il serait également pertinent d'intégrer des données complémentaires, telles que des informations climatiques plus fines ou des données temporelles, afin de mieux prendre en compte les variations saisonnières et régionales de la consommation énergétique. L'exploration d'autres modèles ou de méthodes d'optimisation des hyperparamètres pourrait aussi permettre d'améliorer encore les performances.

Du point de vue applicatif, l'interface Streamlit pourrait être enrichie avec des fonctionnalités supplémentaires, comme l'estimation du coût des travaux de rénovation, le calcul du temps de retour sur investissement ou la comparaison de

plusieurs scénarios de rénovation. Une personnalisation plus poussée des paramètres utilisateur renforcerait également l'intérêt de l'outil.

Enfin, ce projet pourrait être étendu à une utilisation à plus grande échelle, par exemple en tant qu'outil d'aide à la décision pour des collectivités ou des acteurs publics, contribuant ainsi à une meilleure compréhension des enjeux énergétiques et à l'accompagnement de la transition énergétique.

Références

[1] <https://www.iea.org/countries/france/efficiency-demand>

[2] <https://www.statistiques.developpement-durable.gouv.fr/edition-numerique/chiffres-cles-du-climat/en/14-residential-and-services-ghg-emissions>